



# 金融大数据分析 研究生课程

## 第二讲 静态网页爬虫

---

金融学院

许泳昊

xuyonghao@zeul.edu.cn

---

# 目录

## 1 爬虫简介

## 2 静态网页爬虫原理

## 3 静态网页爬虫案例

## 4 课堂练习



## 1.1 爬虫简介

---

- 爬虫是一种自动化的网络机器人，用于从互联网上抓取和收集数据。根据需要，爬虫可以用于从各种网站中获取所需的信息，如天气预报、新闻报道、社交媒体上的内容等。
- 爬虫通常使用各种编程语言和库来构建，如Python的BeautifulSoup和Scrapy等库。爬虫的主要工作原理是发送HTTP请求到目标网站，并解析返回的HTML内容，以从中提取所需的数据。
- 这些数据可以保存在本地文件、数据库或其他存储介质中，以便后续分析和利用。
- 使用爬虫时需要遵守网站的robots.txt文件中的规则和协议，以避免侵犯他人的合法权益或对网站造成过大的负担。



## 1.1 爬虫简介

---

- 静态网页爬虫和动态网页爬虫是**按照网页生成的方式**进行分类的，它们在抓取和解析网页数据方面有一些不同。
- 静态网页爬虫主要针对静态网页，它抓取的网页内容是事先由网站开发者编写好并发布在网站上的。静态网页爬虫通过发送HTTP请求获取HTML页面内容，然后使用解析库（如**BeautifulSoup**、lxml等）将其解析成可读取的结构化数据。静态网页爬虫在处理上比较简单，只需关注网页结构即可，适合抓取内容相对固定的网页。
- 动态网页爬虫则主要针对动态网页，这种网页的内容是在服务器端生成的，根据用户的请求动态展示不同的内容。动态网页爬虫需要处理JavaScript渲染、API接口调用等情况，因此比静态网页爬虫要复杂得多。动态网页爬虫需要使用特定的工具或库（如**Selenium**、Pyppeteer等）来模拟浏览器行为，以便获取页面中的动态内容。



## 1.2 爬虫简介 – 静态网页

外交部网站举例

[https://www.mfa.gov.cn/web/wjdt\\_674879/fyrbt\\_674889/202309/t20230928\\_11152824.shtml](https://www.mfa.gov.cn/web/wjdt_674879/fyrbt_674889/202309/t20230928_11152824.shtml)

首页 > 外交动态 > 发言人表态

### 2023年9月28日外交部发言人毛宁主持例行记者会

2023-09-28 17:35

【中 大 小】 打印 分享



经中德双方商定，第三次中德高级别财金对话将于10月1日在德国举行。中共中央政治局委员、国务院副总理、中德高级别财金对话中方牵头人何立峰将与德国财政部长、对话德方牵头人克里斯蒂安·林德纳共同主持对话。

彭博社记者：美国华盛顿国家动物园的三只大熊猫将于12月底前返回中国。美国亚特兰大、圣地亚哥和孟菲斯动物园的大熊猫要么已经回到中国，要么将在明年年底前回中国。大熊猫离开美国动物园是否反映出中美关系紧张的加剧？外交部如何看待大熊猫外交？





## 1.2 爬虫简介 – 静态网页

[https://www.mfa.gov.cn/web/wjdt\\_674879/fyrbt\\_674889/202309/t20230928\\_11152824.shtml](https://www.mfa.gov.cn/web/wjdt_674879/fyrbt_674889/202309/t20230928_11152824.shtml)

```
<meta name="ColumnType" content="发言人表态" />
<meta name="ColumnDescription" content="发言人表态">
<meta name="ColumnKeywords" content="发言人表态">
<meta name="ArticleTitle" content="2023年9月28日外交部发言人毛宁主持例行记者会" />
<meta name="PubDate" content="2023-09-28" />
<meta name="ContentSource" content="" />
<meta name="Keywords" content="发言人;毛宁" />
<meta name="Author" content="" />
<meta name="Description" content="2023年9月28日外交部发言人毛宁主持例行记者会" />
<meta name="Url" content="https://www.mfa.gov.cn/web/wjdt_674879/fyrbt_674889/202309/t20230928_11152824.shtml" />
<title>2023年9月28日外交部发言人毛宁主持例行记者会_中华人民共和国外交部</title>
```

```

```

<p style="text-indent: 2em;">经中德双方商定，第三次中德高级别财金对话将于10月1日在德国举行。中共中央政治局委员、国务院副总理、中德高级别财金对话中方牵头人何立峰将与德国财政部长、对话德方牵头人克里斯蒂安·林德纳共同主持对话。



# 1.3 爬虫简介 – 动态网页

http://roadshow.sseinfo.com/roadshowIndex.do?id=15749

## 互动交流

最新回复

☒ 自动刷新

上证路演中心

3小时前

本次春秋航空2023年半年度业绩说明会到此圆满结束。感谢各位投资者和网友的积极参与，如各位还有进一步的问题，可通过上证e互动平台与公司保持沟通，谢谢！

王煜(董事长)

3小时前

公司本场业绩会交流到此结束，感谢各位投资者的参与！

上证路演中心

3小时前

各位投资者、各位网友，本次春秋航空2023年半年度业绩说明会已经接近尾声，我们请上市公司嘉宾作总结发言。

消息如风 问 首席财务官兼董事会秘书 陈可

3小时前

陈总好，今天公司发布了9月回购公告，回购总计4,143,763.00元，与回购总额相差甚远，是公司认为目前股价仍然较高导致回购动作缓慢吗？

首席财务官兼董事会秘书 陈可 答

3小时前

您好！公司本次回购授权期限为12个月，按照交易所相关规定，公司应在每个月的前3个交易日内公告截至上月末的回购进展情况，因此本次公告仅为9月回购情况，请您持续关注公司公告。谢谢！

## 用户提问

本次活动已结束，您可登录“上证e互动平台”（<http://sns.sseinfo.com/>）继续向上市公司提问，感谢您的热情参与！

```
<div class="question"></div>
<div class="answer" style="border-bottom: 1px solid #eee"></div>
<div class="question"></div>
<div class="answer" style="border-bottom: 1px solid #eee"></div>
<div class="question"></div>
<div class="answer" style="border-bottom: 1px solid #eee"></div>
<div class="question"></div>
<div class="answer" style="border-bottom: 1px solid #eee"></div>
<div class="question"></div>
<div class="answer" style="border-bottom: 1px solid #eee"></div>
<div style="border-bottom: 1px solid #eee"></div>
<div style="border-bottom: 1px solid #eee"></div>
<div style="border-bottom: 1px solid #eee"></div>
<div style="border-bottom: 1px solid #eee"></div>
<form action="post"></form>
<script></script>
</div>
<!-- 互动正文end -->
</div>
<div class="interaction-right content_right_mb content_new"></div>
</div>
<div style="clear: both"></div>
</section>
</div>
<script type="text/javascript" src="//media.sseinfo.com/roadshow/resources/js/jquery-1.11.2.min.js"></script>
<script type="text/javascript" src="//media.sseinfo.com/roadshow/resources/js/iBox/jquery.iBox-2.3.min.js"></script>
</script></script>
<style></style>
<!-- 相关公告开始 -->
<section id="cd-placeholder-xggs" class="cd-section cd-container hidden-xs"></section>
<!-- 相关公告结束 -->
<!-- 手机版 -->
<div class="hotPoint-mb2018 visible-xs sz" id="相关公告" style"></div>
</div>
</div>
<!-- 引入页脚 -->
<!-- 国际投资者大会基于中文版定制改造（英文版无权限控制）：isSpecial==3中文活动、isSpecial==4英文活动 -->
<div class="footer pa "></div>
<div class="ht-alert" id="opencopyright" style="z-index: 999999; display: none;"></div>
<div class="ht-alert" id="openrelief" style="z-index: 999999; display: none "></div>
<div class="ht-alert" id="openmanage" style="z-index: 999999; display: none "></div>
```



## 1.4 爬虫文本数据分析案例

*The Journal of* FINANCE

*The Journal of* THE AMERICAN FINANCE ASSOCIATION


THE JOURNAL OF FINANCE • VOL. LXXIX, NO. 5 • OCTOBER 2024

### Business News and Business Cycles

LELAND BYBEE, BRYAN KELLY, ASAF MANELA, and DACHENG XIU\*

#### ABSTRACT

We propose an approach to measuring the state of the economy via textual analysis of business news. From the full text of 800,000 *Wall Street Journal* articles for 1984 to 2017, we estimate a topic model that summarizes business news into interpretable topical themes and quantifies the proportion of news attention allocated to each theme over time. News attention closely tracks a wide range of economic activities and can forecast aggregate stock market returns. A text-augmented vector autoregression demonstrates the large incremental role of news text in forecasting macroeconomic dynamics. We retrieve the narratives that underlie these improvements in market and business cycle forecasts.







1998, 1999, 2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020, 2021, 2022, 2023, 2024, 2025, 2026, 2027, 2028, 2029, 2030, 2031, 2032, 2033, 2034, 2035, 2036, 2037, 2038, 2039, 2040, 2041, 2042, 2043, 2044, 2045, 2046, 2047, 2048, 2049, 2050, 2051, 2052, 2053, 2054, 2055, 2056, 2057, 2058, 2059, 2060, 2061, 2062, 2063, 2064, 2065, 2066, 2067, 2068, 2069, 2070, 2071, 2072, 2073, 2074, 2075, 2076, 2077, 2078, 2079, 2080, 2081, 2082, 2083, 2084, 2085, 2086, 2087, 2088, 2089, 2090, 2091, 2092, 2093, 2094, 2095, 2096, 2097, 2098, 2099, 2100, 2101, 2102, 2103, 2104, 2105, 2106, 2107, 2108, 2109, 2110, 2111, 2112, 2113, 2114, 2115, 2116, 2117, 2118, 2119, 2120, 2121, 2122, 2123, 2124, 2125, 2126, 2127, 2128, 2129, 2130, 2131, 2132, 2133, 2134, 2135, 2136, 2137, 2138, 2139, 2140, 2141, 2142, 2143, 2144, 2145, 2146, 2147, 2148, 2149, 2150, 2151, 2152, 2153, 2154, 2155, 2156, 2157, 2158, 2159, 2160, 2161, 2162, 2163, 2164, 2165, 2166, 2167, 2168, 2169, 2170, 2171, 2172, 2173, 2174, 2175, 2176, 2177, 2178, 2179, 2180, 2181, 2182, 2183, 2184, 2185, 2186, 2187, 2188, 2189, 2190, 2191, 2192, 2193, 2194, 2195, 2196, 2197, 2198, 2199, 2200, 2201, 2202, 2203, 2204, 2205, 2206, 2207, 2208, 2209, 2210, 2211, 2212, 2213, 2214, 2215, 2216, 2217, 2218, 2219, 2220, 2221, 2222, 2223, 2224, 2225, 2226, 2227, 2228, 2229, 2230, 2231, 2232, 2233, 2234, 2235, 2236, 2237, 2238, 2239, 2240, 2241, 2242, 2243, 2244, 2245, 2246, 2247, 2248, 2249, 2250, 2251, 2252, 2253, 2254, 2255, 2256, 2257, 2258, 2259, 2260, 2261, 2262, 2263, 2264, 2265, 2266, 2267, 2268, 2269, 2270, 2271, 2272, 2273, 2274, 2275, 2276, 2277, 2278, 2279, 2280, 2281, 2282, 2283, 2284, 2285, 2286, 2287, 2288, 2289, 2290, 2291, 2292, 2293, 2294, 2295, 2296, 2297, 2298, 2299, 2300, 2301, 2302, 2303, 2304, 2305, 2306, 2307, 2308, 2309, 2310, 2311, 2312, 2313, 2314, 2315, 2316, 2317, 2318, 2319, 2320, 2321, 2322, 2323, 2324, 2325, 2326, 2327, 2328, 2329, 2330, 2331, 2332, 2333, 2334, 2335, 2336, 2337, 2338, 2339, 2340, 2341, 2342, 2343, 2344, 2345, 2346, 2347, 2348, 2349, 2350, 2351, 2352, 2353, 2354, 2355, 2356, 2357, 2358, 2359, 2360, 2361, 2362, 2363, 2364, 2365, 2366, 2367, 2368, 2369, 2370, 2371, 2372, 2373, 2374, 2375, 2376, 2377, 2378, 2379, 2380, 2381, 2382, 2383, 2384, 2385, 2386, 2387, 2388, 2389, 2390, 2391, 2392, 2393, 2394, 2395, 2396, 2397, 2398, 2399, 2400, 2401, 2402, 2403, 2404, 2405, 2406, 2407, 2408, 2409, 2410, 2411, 2412, 2413, 2414, 2415, 2416, 2417, 2418, 2419, 2420, 2421, 2422, 2423, 2424, 2425, 2426, 2427, 2428, 2429, 2430, 2431, 2432, 2433, 2434, 2435, 2436, 2437, 2438, 2439, 2440, 2441, 2442, 2443, 2444, 2445, 2446, 2447, 2448, 2449, 2450, 2451, 2452, 2453, 2454, 2455, 2456, 2457, 2458, 2459, 2460, 2461, 2462, 2463, 2464, 2465, 2466, 2467, 2468, 2469, 2470, 2471, 2472, 2473, 2474, 2475, 2476, 2477, 2478, 2479, 2480, 2481, 2482, 2483, 2484, 2485, 2486, 2487, 2488, 2489, 2490, 2491, 2492, 2493, 2494, 2495, 2496, 2497, 2498, 2499, 2500, 2501, 2502, 2503, 2504, 2505, 2506, 2507, 2508, 2509, 2510, 2511, 2512, 2513, 2514, 2515, 2516, 2517, 2518, 2519, 2520, 2521, 2522, 2523, 2524, 2525, 2526, 2527, 2528, 2529, 2530, 2531, 2532, 2533, 2534, 2535, 2536, 2537, 2538, 2539, 2540, 2541, 2542, 2543, 2544, 2545, 2546, 2547, 2548, 2549, 2550, 2551, 2552, 2553, 2554, 2555, 2556, 2557, 2558, 2559, 2560, 2561, 2562, 2563, 2564, 2565, 2566, 2567, 2568, 2569, 2570, 2571, 2572, 2573, 2574, 2575, 2576, 2577, 2578, 2579, 2580, 2581, 2582, 2583, 2584, 2585, 2586, 2587, 2588, 2589, 2590, 2591, 2592, 2593, 2594, 2595, 2596, 2597, 2598, 2599, 2600, 2601, 2602, 2603, 2604, 2605, 2606, 2607, 2608, 2609, 2610, 2611, 2612, 2613, 2614, 2615, 2616, 2617, 2618, 2619, 2620, 2621, 2622, 2623, 2624, 2625, 2626, 2627, 2628, 2629, 2630, 2631, 2632, 2633, 2634, 2635, 2636, 2637, 2638, 2639, 2640, 2641, 2642, 2643, 2644, 2645, 2646, 2647, 2648, 2649, 2650, 2651, 2652, 2653, 2654, 2655, 2656, 2657, 2658, 2659, 2660, 2661, 2662, 2663, 2664, 2665, 2666, 2667, 2668, 2669, 2670, 2671, 2672, 2673, 2674, 2675, 2676, 2677, 2678, 2679, 26



## 1.4 爬虫文本数据分析案例



## 1.4 爬虫文本数据分析案例

经济字

DOI:10.19744/j.cnki.11-1235/f.2024.0090

# 大语言模型、文本情绪 与金融市场\*

姜富伟 刘雨旻 孟令超

**摘要:**“人工智能+”行动是发展新质生产力的重要途径,其在金融领域的应用有助于金融强国建设。本文创新性地融合结构化金融市场数据和非结构化金融文本大数据,并结合中国特色金融市场的独特特征,训练了一个更适用于我国金融领域的中文金融大语言模型,并开展金融市场情绪测度和资产价格风险预测。研究发现,与传统字典法相比,使用中文金融大语言模型构建的大模型情绪在金融市场回报预测方面表现显著更佳。大模型情绪对很多宏观经济变量也有显著预测能力,能够捕捉非理性情绪冲击对宏观经济基本面的影响。大模型情绪在经济下行和极端风险事件期间的预测效果更强,契合了金融理论中非理性情绪对金融市场和宏观经济会产生非对称与非线性影响的结果。综上,本研究展现了“人工智能+”行动在我国金融领域应用落地的潜在技术路径和理论逻辑。

**关键词:** 文本情绪 深度学习 大语言模型 资产定价

## 1.4 爬虫文本数据分析案例

2024 年第 8 期




图4 情绪变量与上证指数收益率时序变化



# 目录

1 爬虫简介

2 静态网页爬虫原理

3 静态网页爬虫案例

4 课堂练习





## 2 静态网页爬虫原理

---

- 1. 确定目标网站和URL地址：**首先，你需要明确你要爬取的目标网站，并获取该网站的URL地址。
- 2. 网络请求：**通过HTTP协议向目标网站发送请求。这可以通过使用Python中的requests库或其他编程语言中的类似库来实现。请求可以包含额外的headers等信息，以便模拟浏览器行为或进行特定配置。
- 3. 获取网页内容：**发送请求后，你将收到目标网站的响应，其中包括网页的HTML代码和其他相关信息。对于获取到的HTML代码，需要使用解析库（如BeautifulSoup、lxml等）将其解析成可读取的结构化数据。这些库能够根据HTML的结构，识别并提取出所需的文本、链接、图片等信息。
- 4. 数据存储：**将解析出来的数据根据需要进行存储。可以将其保存为文本文件、数据库或特定的文件格式。
- 5. 循环遍历：**以上面的步骤为基础，不断循环遍历目标网站的所有页面，完成数据的全面抓取。



## 2.1 地址获取

---

- 1.URL地址错误：如果提供的URL地址不正确或已过期，将无法访问目标网站，因此需要确保URL地址的正确性。
- 2.网站限制：一些网站可能采取限制措施，如IP限制、访问频率限制等，导致无法在短时间内大量抓取数据。此时，需要合理配置爬取速率和访问频率，以免触发网站的限制机制。
- 3.需要登录的网站：对于需要登录的网站，需要先通过登录获取访问权限，才能进一步进行网页抓取。此时，需要注意登录操作过程中可能出现的错误和异常，如密码错误、验证码等。
- 4.网站结构变化：网站结构经常会发生改变，尤其是大型网站。这可能导致之前的爬取脚本无法正常工作，需要进行相应的调整和修改。
- 5.HTTP状态码问题：HTTP状态码是服务器返回给客户端的状态信息，其中可能包含了一些错误提示。如果爬取过程中遇到HTTP状态码错误，需要及时处理并解决相关问题。

针对以上问题，建议在确定目标网站和URL地址之前，先对网站进行一定的了解和分析，包括网站结构、页面内容、访问频率等方面。同时，也需要仔细阅读网站的Robots协议和其他相关文档，以了解网站的使用规范和限制条件。



## 2.1 地址获取

---

Robots协议是网站与爬虫之间的一种协议，用于规范爬虫的行为。Robots协议通常以文本形式存在于网站的根目录下，以"robots.txt"为文件名。要调取网站Robots协议，可以按照以下步骤进行：

- 在浏览器中打开目标网站。
- 在浏览器地址栏中输入以下网址："http://www.目标网站域名/robots.txt"。例如，如果目标网站域名为example.com，则输入"http://www.example.com/robots.txt"。
- 按下回车键，浏览器将显示该网站的Robots协议文件内容。

Robots协议文件通常包括以下内容：

- 爬虫的命名规则和访问权限分配。
- 禁止爬取的URL地址列表。
- 爬虫的访问频率和抓取限制。



## 2.1 地址获取

---

Robots协议是网站与爬虫之间的一种协议，用于规范爬虫的行为。Robots协议通常以文本形式存在于网站的根目录下，以"robots.txt"为文件名。要调取网站Robots协议，可以按照以下步骤进行：

- 在浏览器中打开目标网站。
- 在浏览器地址栏中输入以下网址："http://www.目标网站域名/robots.txt"。例如，如果目标网站域名为example.com，则输入"http://www.example.com/robots.txt"。
- 按下回车键，浏览器将显示该网站的Robots协议文件内容。


Robots协议文件通常包括以下内容：

- 爬虫的命名规则和访问权限分配。
- 禁止爬取的URL地址列表。
- 爬虫的访问频率和抓取限制。



## 2.1 地址获取

地址获取实际上较为复杂的地方在于如何批量的获取同一个网站（如外交部官网）里不同子网页（不同日期的外交部发言记录）的网址



## 2.2 读取网页并返回文档内容

```
n [33]: from bs4 import BeautifulSoup
import requests
```

```
n [34]: url = "https://www.mfa.gov.cn/web/wjdt_674879/fyrbt_674889/" # 替换成目标网页的URL地址
```

```
n [35]: def get_one_page(url):
        response=requests.get(url)
        response.encoding='utf-8'
        return response.text
```

```
n [36]: text=get_one_page(url)
```

```
n [37]: print(text)
```

```
<!DOCTYPE html>
<html>
<head>
<meta charset="utf-8">
<meta http-equiv="X-UA-Compatible" content="IE=edge,chrome=1">
<meta name="viewport" content="width=device-width, maximum-scale=1, initial-scale=1, user-scalable=yes">
<meta name="SiteName" content="中华人民共和国外交部">
<meta name="SiteDomain" content="www.mfa.gov.cn">
<meta name="SiteIDCode" content="bm02000004">
<meta name="ColumnName" content="发言人表态">
<meta name="ColumnType" content="发言人表态">
<meta name="ColumnDescription" content="发言人表态">
<meta name="ColumnKeywords" content="发言人表态">
<title>发言人表态_中华人民共和国外交部</title>
<link rel="stylesheet" type="text/css" href="../../images/style_20210817.css" />
<link rel="stylesheet" type="text/css" href="../../images/responsive_20210817.css">
<script type="text/javascript" src="../../images/jqueryv1.42.min_20210817.js"></script>
```





## 2.3 BeautifulSoup提取数据

---

- 安装BeautifulSoup (`pip3 install beautifulsoup4`)
- 导入BeautifulSoup库 (`from bs4 import BeautifulSoup`)



## 2.3 BeautifulSoup提取数据

---

### BeautifulSoup的使用方式

- 创建BeautifulSoup对象（`soup = BeautifulSoup(html_content, 'html.parser')`）
- 通过选择器查找元素（`element = soup.select_one("div.content")`）
- 通过标签名查找元素（`elements = soup.find_all("a")`）
- 通过属性查找元素（`elements = soup.find_all("a", href=True)`）



## 2.3 BeautifulSoup提取数据

```
] : def crawl(url):  
    html=get_one_page(url)  
    soup = BeautifulSoup(html,'lxml')  
    time =soup.find(attrs={'class':'time'})  
    print("时间: ",time.text)  
    content=soup.find_all(attrs={'class':'news-main'})  
    output={'问答/n'}  
    title=soup.find(name='title')  
    print("标题: ",title.string)  
    #print(content)  
    for qanda in content:  
        temp2=qanda.get_text()  
        temp3=str(temp2.strip())  
        print(temp3)
```

```
] : test_url="https://www.mfa.gov.cn/web/wjdt_674879/fyrbt_674889/202309/t20230913_11142325.shtml"
```

```
] : crawl(test_url)
```

时间: 2023-09-13 19:30

标题: 2023年9月13日外交部发言人毛宁主持例行记者会\_中华人民共和国外交部

法新社记者: 朝鲜领导人金正恩和俄罗斯总统普京今天在俄罗斯东部会面。金正恩表示将把发展朝鲜与俄罗斯的关系作为首要任务。请问这对中国与朝鲜的关系意味着什么? 毛宁: 朝鲜领导人对俄罗斯的访问, 是朝俄之间的安排, 涉及的是朝俄关系。关于中朝关系, 中朝是山水相连的友好邻邦。中朝关系发展良好, 双方正在贯彻落实两国最高领导人达成的重要共识, 深化两国各领域交流合作, 推动中朝传统友好合作关系不断取得新的更大发展。总台央视记者: 我们注意到, 外交部今天发布了《关于全球治理变革和建设的中国方案》。发言人能否介绍有关情况? 毛宁: 近日, 第78届联合国大会开幕, 9月19日至26日将举行联大一般性辩论。当前, 国际形势变乱交织, 各种全球性挑战层出不穷, 国际社会期待联合国在国际事务中发挥积极作用, 不断改革和完善全球治理体系。本届联大将为国际社会凝聚政治共识、增进团结协作、携手应对挑战提供重要契机。《关于全球治理变革和建设的中国方案》全面阐述了中方对和平安全、发展、人权、社会、新疆域等全球治理重点领域及多边机构改革的立场主张, 呼吁国际社会共同落实全球发展倡议、全球安全倡议、全球文明倡议, 推动构建人类命运共同体, 展现了中国在国际事务中的大国担当和建设性作用。在联大开幕之际, 中方发布这一方案, 为全球治理体系变革贡献了中国智慧。中方愿同各方一道努力, 践行真正的多边主义, 为世界和平、发展与人权事业不断作出新的贡献。湖北广电记者: 9月12日是联合国南南合作日。中方如何看待南南合作的意义? 将如何进一步促进南南合作? 毛宁: 南南合作体现了发展中国家团结合作、同舟共济的精神。推进南南合作有助于维护发展中国家共同利益, 加速全球经济、社会和环境的可持续发展, 推动实现更加公平和包容的全球治理。作为最大的发展中国家, 中国一直是南南合作的倡导者和参与者, 在减贫、粮食安全、农业技术、公共卫生、工业化、气候变化等领域积极推进南南合作, 以自身发展惠及全球发展。2021年, 习近平主席提出全球发展倡议。在倡议框架下, 中方同各方特别是发展中国家密切合作, 支持各国加快实现可持续发展目标, 200多个合作项目已经开花结果, 倡议“之友小组”成员国达到70多个。在刚刚结束的金砖国家领导人会晤中, 习近平主席表示, 中方加大了资源投入, 已经成立全球发展和南南合作基金, 中国金融机构即将推出专项资金, 专门用于落实全球发展倡议。中方将继续同各方携手推进南南合作, 构建发展共同体, 让所有国家共享发展成果。法新社记者: 上周, 美国和加拿大的军舰通过台湾海峡。近有报道称, 中国在台湾岛附近海域进行大型军事演习。外交部能否进一步介绍有关情况? 毛宁: 关于美加军舰过航台湾海峡, 中国人民解放军东部战区新闻发言人已发表谈话, 你可以查阅。我要强调, 台湾是中国领土不可分割的一部分, 中方捍卫国家主权和领土完整的决心坚定不移。有关方面应当立即停止此类挑衅举动, 不要做台海和平稳定的破坏制造者。共同记者: 国土新闻网中方发言人进行直播时, 在直播中多次表示, 中方在维护国家主权和领土完整方面, 将采取一切必要措施, 坚决捍卫国家主权和领土完整。



## 2.3 BeautifulSoup提取数据

### ● 选择元素

下面再用一个例子详细说明选择元素的方法：

```
html = """
<html><head><title>The Dormouse's story</title></head>
<body>
<p class="title" name="dromouse"><b>The Dormouse's story</b></p>
<p class="story">Once upon a time there were three little sisters; and their names were
<a href="http://example.com/elsie" class="sister" id="link1"><!-- Elsie --></a>,
<a href="http://example.com/lacie" class="sister" id="link2">Lacie</a> and
<a href="http://example.com/tillie" class="sister" id="link3">Tillie</a>;
and they lived at the bottom of a well.</p>
<p class="story">...</p>
"""

from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'lxml')
print(soup.title)
print(type(soup.title))
print(soup.title.string)
print(soup.head)
print(soup.p)
```

运行结果如下：

```
<title>The Dormouse's story</title>
<class 'bs4.element.Tag'>
The Dormouse's story
<head><title>The Dormouse's story</title></head>
<p class="title" name="dromouse"><b>The Dormouse's story</b></p>
```



## 2.3 BeautifulSoup提取数据

### (1) 获取名称

可以利用 name 属性获取节点的名称。这里还是以上面的文本为例，选取 title 节点，然后调用 name 属性就可以得到节点名称：

```
print(soup.title.name)
```

运行结果如下：

```
title
```

### (2) 获取属性

每个节点可能有多个属性，比如 id 和 class 等，选择这个节点元素后，可以调用 attrs 获取所有属性：

```
print(soup.p.attrs)
print(soup.p.attrs['name'])
```

运行结果如下：

```
{'class': ['title'], 'name': 'dromouse'}
dromouse
```



## 2.3 BeautifulSoup提取数据

---

### (3)获取内容

可以利用 string 属性获取节点元素包含的文本内容，比如要获取第一个 p 节点的文本：

```
print(soup.p.string)
```

运行结果如下：

```
The Dormouse's story
```

再次注意一下，这里选择到的 p 节点是第一个 p 节点，获取的文本也是第一个 p 节点里面的文本。





## 2.3 BeautifulSoup提取数据

### ● 关联选择

在做选择的时候，有时候不能做到一步就选到想要的节点元素，需要先选中某一个节点元素，然后以它为准再选择它的子节点、父节点、兄弟节点等，这里就来介绍如何选择这些节点元素。

#### (1) 子节点和子孙节点

```
html = """
<html>
<head>
<title>The Dormouse's story</title>
</head>
<body>
<p class="story">
  Once upon a time there were three little sisters; and their names were
  <a href="http://example.com/elsie" class="sister" id="link1">
<span>Elsie</span>
</a>
  <a href="http://example.com/lacie" class="sister" id="link2">Lacie</a>
  and
  <a href="http://example.com/tillie" class="sister" id="link3">Tillie</a>
  and they lived at the bottom of a well.
</p>
<p class="story">...</p>
"""
from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'lxml')
print(soup.p.contents)
```

运行结果如下：

```
['\n      Once upon a time there were three little sisters; and their names were\n      href="http://example.com/elsie" id="link1">\n<span>Elsie</span>\n</a>', '\n', <a class="sister" href="http://example.com/lacie" id="link2">Lacie</a>', '\n      and\n      ',\n<a class="sister" href="http://example.com/tillie" id="link3">Tillie</a>', '\n      and they lived at\n      the bottom of a well.\n']
```

可以看到，返回结果是列表形式。p 节点里既包含文本，又包含节点，最后会将它们以列表形式统一返回。



## 2.3 BeautifulSoup提取数据

---

同样，我们可以调用 children 属性得到相应的结果：

```
from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'lxml')
print(soup.p.children)
for i, child in enumerate(soup.p.children):
    print(i, child)
```

如果要得到所有的子孙节点的话，可以调用 descendants 属性：

```
from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'lxml')
print(soup.p.descendants)
for i, child in enumerate(soup.p.descendants):
    print(i, child)
```



## 2.3 BeautifulSoup提取数据

### 6. 方法选择器

前面所讲的选择方法都是通过属性来选择的，这种方法非常快，但是如果进行比较复杂的选择的话，它就比较烦琐，不够灵活了。幸好，Beautiful Soup 还为我们提供了一些查询方法，比如 `find_all()` 和 `find()` 等，调用它们，然后传入相应的参数，就可以灵活查询了。

- `find_all()`

`find_all`，顾名思义，就是查询所有符合条件的元素。给它传入一些属性或文本，就可以得到符合条件的元素，它的功能十分强大。

它的 API 如下：

```
find_all(name , attrs , recursive , text , **kwargs)
```

#### (2) `attrs`

除了根据节点名查询，我们也可以传入一些属性来查询，示例如下：

#### (3) `text`

`text` 参数可用来匹配节点的文本，传入的形式可以是字符串，可以是正则表达式对象，示例如下：



## 2.3 BeautifulSoup提取数据

```
import re
html='''
<div class="panel">
<div class="panel-body">
<a>Hello, this is a link</a>
<a>Hello, this is a link, too</a>
</div>
</div>
'''

from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'lxml')
print(soup.find_all(text=re.compile('link')))
```

运行结果如下：

```
['Hello, this is a link', 'Hello, this is a link, too']
```

这里有两个 a 节点，其内部包含文本信息。这里在 find\_all() 方法中传入 text 参数，该参数为正则表达式对象，结果返回所有匹配正则表达式的节点文本组成的列表。



## 2.3 BeautifulSoup提取数据

- `find()`

除了 `find_all()` 方法，还有 `find()` 方法，只不过后者返回的是单个元素，也就是第一个匹配的元素，而前者返回的是所有匹配的元素组成的列表。示例如下：

BeautifulSoup (bs4) 是一个用于解析HTML和XML文档的Python库，它提供了许多方便的方法用于搜索和提取文档中的数据。 `find` 函数是BeautifulSoup中非常常用的一个方法，用于在文档树中查找第一个符合条件的标签。

### `find` 函数的基本用法

#### python

```
1 find(name, attrs, recursive, string, **kwargs)
```

- `name`: 标签名，可以是字符串或正则表达式。
- `attrs`: 一个字典，用于匹配标签的属性。
- `recursive`: 是否递归地查找子标签。默认值为True。
- `string`: 用于匹配标签包含的文本内容。
- `kwargs`: 其他可以传递给标签的属性。



## 2.3 BeautifulSoup提取数据

```
In [27]: from bs4 import BeautifulSoup
import re
html = """
<html>
  <head>
    <title>My Title</title>
  </head>
  <body>
    <div class="content">
      <p id="first">First paragraph.</p>
      <p id="second">Second paragraph.</p>
    </div>
  </body>
</html>
"""
```

1 我们可以使用find函数来查找第一个

标签:

```
In [28]: soup = BeautifulSoup(html, 'html.parser')
first_p = soup.find('p')
print(first_p)
# 输出: <p id="first">First paragraph.</p>
```

<p id="first">First paragraph.</p>



## 2.3 BeautifulSoup提取数据

2. 查找带有特定属性的标签 我们可以查找具有特定属性的标签，例如查找id为"second"的标签：

```
second_p = soup.find('p', id='second')
print(second_p)
# 输出: <p id="second">Second paragraph. </p>
```

<p id="second">Second paragraph. </p>

3. 查找带有特定类名的标签 假设我们要查找类名为"content"的标签：


```
content_div = soup.find('div', class_='content')
print(content_div)
# 输出: <div class="content">
#       <p id="first">First paragraph. </p>
#       <p id="second">Second paragraph. </p>
#       </div>
```

<div class="content">  
<p id="first">First paragraph. </p>  
<p id="second">Second paragraph. </p>  
</div>

4. 查找包含特定文本内容的标签 假设我们要查找包含"Second"这个字符串的标签：

```
second_p_with_text = soup.find('p', string=re.compile('Second'))
print(second_p_with_text)
print(second_p_with_text.text)
```

<p id="second">Second paragraph. </p>  
Second paragraph.





## 2.3 BeautifulSoup提取数据

---

<https://www.runoob.com/python/python-reg-expressions.html>

### Python 正则表达式

正则表达式是一个特殊的字符序列，它能帮助你方便的检查一个字符串是否与某种模式匹配。

Python 自1.5版本起增加了re 模块，它提供 Perl 风格的正则表达式模式。

re 模块使 Python 语言拥有全部的正则表达式功能。

compile 函数根据一个模式字符串和可选的标志参数生成一个正则表达式对象。该对象拥有一系列方法用于正则表达式匹配和替换。

re 模块也提供了与这些方法功能完全一致的函数，这些函数使用一个模式字符串做为它们的第一个参数。

本章节主要介绍Python中常用的正则表达式处理函数。

---

### re.match函数

re.match 尝试从字符串的起始位置匹配一个模式，如果不是起始位置匹配成功的话，match() 就返回 none。

函数语法：

```
re.match(pattern, string, flags=0)
```



## 2.3 BeautifulSoup提取数据

### re.match函数

re.match 尝试从字符串的起始位置匹配一个模式，如果不是起始位置匹配成功的话，match() 就返回 none。

函数语法：

```
re.match(pattern, string, flags=0)
```

函数参数说明：

| 参数      | 描述                                                                      |
|---------|-------------------------------------------------------------------------|
| pattern | 匹配的正则表达式                                                                |
| string  | 要匹配的字符串。                                                                |
| flags   | 标志位，用于控制正则表达式的匹配方式，如：是否区分大小写，多行匹配等等。参见： <a href="#">正则表达式修饰符 - 可选标志</a> |

匹配成功 re.match 方法返回一个匹配的对象，否则返回 None。

我们可以使用 group(num) 或 groups() 匹配对象函数来获取匹配表达式。

| 匹配对象方法       | 描述                                                        |
|--------------|-----------------------------------------------------------|
| group(num=0) | 匹配的整个表达式的字符串，group() 可以一次输入多个组号，在这种情况下它将返回一个包含那些组所对应值的元组。 |
| groups()     | 返回一个包含所有小组字符串的元组，从 1 到 所含的小组号。                            |

#### 实例

```
#!/usr/bin/python
# -*- coding: UTF-8 -*-

import re
print(re.match('www', 'www.runoob.com').span()) # 在起始位置匹配
print(re.match('com', 'www.runoob.com'))        # 不在起始位置匹配
```



# 目录

1 爬虫简介

2 静态网页爬虫原理


3 静态网页爬虫案例

4 课堂练习




### 3 静态网页爬虫案例


---



1 循环获取外交部讲话的网址数据，并进行存储



2 单独爬取一个网址里的外交部发言数据



3 循环读取网址数据，并逐步爬取网页的外交部发言的文本数据



# 目录

1 爬虫简介

2 静态网页爬虫原理

3 静态网页爬虫案例

4 课堂练习



## 4 课堂练习 – 数据举例说明

---

### 经济和金融领域

#### 1. 财经新闻与公告:

1. 财经新闻网站（如财新网、华尔街见闻等）上发布的最新财经新闻，包括公司财报、市场动态、政策解读等。
2. 证券交易所发布的上市公司公告，这些公告通常包含公司的财务状况、重大事项、风险提示等重要信息。

#### 2. 市场研究报告:

1. 各大研究机构发布的市场研究报告，这些报告通常包含行业趋势分析、市场规模预测、竞争格局评估等非结构化数据。

#### 3. 社交媒体情绪分析:

1. 爬取社交媒体（如微博、Twitter）上用户对特定经济事件、金融产品或公司的评论和反馈，用于情感分析，了解公众舆论和市场情绪。

#### 4. 金融数据平台的深度报告:

1. 某些金融数据平台（如Wind资讯、彭博终端）上提供的深度研究报告和分析文章，这些报告通常包含专家观点、数据图表和详细分析。



## 4 课堂练习 – 数据举例说明

---

### 政府相关领域

#### 1. 政府公告与法规:

1. 政府部门官方网站发布的公告、通知、政策文件等，这些文件包含政府决策、政策导向、行业规范等重要信息。

#### 2. 统计数据与报告:

1. 国家统计局、各地方统计局以及政府各部门发布的统计数据和专题报告，如GDP增长率、CPI指数、行业运行数据等。

#### 3. 政府采购信息:

1. 政府采购网站上发布的采购公告、中标结果等信息，这些信息反映了政府的采购需求和资金流向。

#### 4. 政策解读与评论:

1. 爬取政府官方网站、新闻网站或社交媒体上关于政府政策的解读和评论文章，了解公众对政府政策的看法和反馈。






## 4 课堂练习

### 1 完成中国人民银行新闻爬取

<http://www.pbc.gov.cn/goutongjiaoliu/113456/113469/11040/index1.html>

#### 新闻

中国区域金融运行报告（2023） 2023-11-09  
中国人民银行、香港金融管理局、澳门金融管理局共同签署《关于在粤港澳大湾区... 2023-11-09  
加强国际宏观政策对话协调 提升全球经济金融韧性——宜昌能副行长2023金融街... 2023-11-09  
中国人民银行行长、国家外汇局局长潘功胜在2023金融街论坛年会上的讲话 2023-11-08  
2023年前三季度地区社会融资规模增量统计表 2023-11-07  
中国人民银行公告（2023）第17号 2023-11-06  
中国人民银行党委 国家外汇局党组召开扩大会议 传达学习中央金融工作会议精... 2023-11-02  
2023年三季度金融机构贷款投向统计报告 2023-11-01  
中国人民银行召开第二批学习贯彻习近平新时代中国特色社会主义思想主题教育... 2023-10-28  
2023年人民币国际化报告 2023-10-27  
中国人民银行召开提升境外来华人员支付服务水平工作动员部署会 2023-10-27  
2023年9月份金融市场运行情况 2023-10-27  
中美金融工作组举行第一次会议 2023-10-27  
中国人民银行召开拒收人民币现金专项整治工作动员部署会 2023-10-26  
中国人民银行公告（2023）第16号 2023-10-23



# 4 课堂练习

## 2 爬取国务院和各省政策文件数据-等

国务院 <https://www.gov.cn/zhengce/zuixin/home.htm>

省政府

<http://www.hubei.gov.cn/zfwj/list1.shtml>

<http://www.hunan.gov.cn/hnszf/xxgk/xxgk.html>



## 4 课堂练习

### 3 完成纪委通报数据爬取

<https://www.ccdi.gov.cn/jdjbnew/wfbxgd/>



中共中央纪律检查委员会



中华人民共和国国家监察委员会

领导活动

信息公开

党纪法规

监督举报

审查调查

巡视巡察

理论学习

历史文化

📍 首页 > 监督举报 > 违反中央八项规定精神问题

山西通报5起违反中央八项规定精神问题

2023-10-10

江西通报8起违反中央八项规定精神典型问题

2023-09-28

云南通报3起公款旅游和变相公款旅游典型问题

2023-09-28

湖南通报6起违规旅游典型问题

2023-09-28

山西通报4起违反中央八项规定精神问题

2023-09-27

甘肃通报5起违反中央八项规定精神问题


2023-09-27

云南通报3起违规吃喝典型问题

2023-09-27

长春通报4起党员领导干部违规收受礼品礼金问题

2023-09-26



## 4 课堂练习

### 4 宏观研究报告

[https://stock.finance.sina.com.cn/stock/go.php/vReport\\_List/kind/macro/index.phtml](https://stock.finance.sina.com.cn/stock/go.php/vReport_List/kind/macro/index.phtml)

| sina 新浪财经                                                                                                                                                                                                                                      |                                    |      |            |              |         |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------|------|------------|--------------|---------|
| 研究报告   最新滚动   主力动向   个股评级   公司研究   行业研究   投资策略   宏观研究   金麒麟研报   更多                                                                                                                                                                             |                                    |      |            |              |         |
| 研报搜索: <input type="radio"/> 研究机构 <input type="radio"/> 公司股票 <input type="radio"/> 行业分类 <input type="radio"/> 分析师 <input type="radio"/> 标题 <input type="radio"/> 发布日期 <input type="text" value="2023-11-13"/> <input type="button" value="搜索"/> |                                    |      |            |              |         |
| 序号                                                                                                                                                                                                                                             | 标题                                 | 报告类型 | 发布日期       | 机构           | 研究员     |
| 1                                                                                                                                                                                                                                              | 10月物价数据点评: 通胀整体偏弱 后续仍将修复           | 宏观   | 2023-11-13 | 国开证券股份有限公司   | 杜征征     |
| 2                                                                                                                                                                                                                                              | 宏观点评: 明年“宽财政”空间有多大?                | 宏观   | 2023-11-13 | 东吴证券股份有限公司   | 陶川/邵翔   |
| 3                                                                                                                                                                                                                                              | 光大宏观周报: 哪些行业在补库?                   | 宏观   | 2023-11-13 | 光大证券股份有限公司   | 高瑞东/刘星展 |
| 4                                                                                                                                                                                                                                              | 宏观快评: 从各部委机构学习会议 看金融工作的5个变化和4大要点   | 宏观   | 2023-11-13 | 华创证券有限责任公司   | 张瑜      |
| 5                                                                                                                                                                                                                                              | 宏观周报: 商品市场重现“内强外弱”的预期              | 宏观   | 2023-11-13 | 国贸期货有限公司     | 郑建鑫     |
| 6                                                                                                                                                                                                                                              | 2023年11月份宏观市场展望分析                  | 宏观   | 2023-11-13 | 瑞达期货股份有限公司   | 许方莉/廖宏海 |
| 7                                                                                                                                                                                                                                              | 政策研究: 习近平将赴美国举行中美元首会晤 穆迪将美国信用评级... | 宏观   | 2023-11-13 | 中信建投证券股份有限公司 | 胡玉玮/杨旭东 |
| 8                                                                                                                                                                                                                                              | 宏观周报: 国内10月物价水平低迷 货币政策仍需宽松         | 宏观   | 2023-11-13 | 浙商期货有限公司     | 沈文卓/朱泉魁 |
| 9                                                                                                                                                                                                                                              | 每周经济观察第44期: 五问“平急两用”基础设施建设         | 宏观   | 2023-11-13 | 华创证券有限责任公司   | 张瑜/陆银波  |
| 10                                                                                                                                                                                                                                             | 宏观经济周报2023年第四十六周                   | 宏观   | 2023-11-13 | 工银国际证券研究有限公司 | 张弘頔/徐婕/ |
| 11                                                                                                                                                                                                                                             | 宏观周报: 10月CPI同比下降; 欧元区PMI走弱         | 宏观   | 2023-11-13 | 上海大陆期货有限公司   | 张璐丝     |
| 12                                                                                                                                                                                                                                             | 中国首席财经                             | 宏观   | 2023-11-13 | 博览财经资讯服务有限公司 | 一一      |
| 13                                                                                                                                                                                                                                             | 宏观周报: 加快建设金融强国                     | 宏观   | 2023-11-13 | 开源证券股份有限公司   | 何宁      |
| 14                                                                                                                                                                                                                                             | 宏观周观点: 怎么看内外边际变化?                  | 宏观   | 2023-11-13 | 招商证券股份有限公司   | 张静静/张一  |
| 15                                                                                                                                                                                                                                             | 【中金宏观】中国高频跟踪数据库                    | 宏观   | 2023-11-13 | 中国国际金融股份有限公司 | 黄文静/段玉  |







谢谢

许泳昊